

Detecção de Anomalias em Estrelas da Via Láctea: Explorando Dados do *Gaia* e Outros *Surveys* com Aprendizado de Máquina II

25 de maio de 2026

Sumário

1	Introdução	2
2	Justificativa	4
3	Referencial Teórico	5
4	Objetivos	6
5	Metodologia	7
6	Resultados Esperados	8
7	Cronograma esperado e execução de tarefas	9
8	Referências	11

Resumo

Texto do Resumo

[MLLD: Uma sugestão:] Este projeto corresponde à segunda fase de uma iniciação científica voltada à caracterização de populações estelares e à detecção de anomalias em estrelas da Via Láctea com técnicas de aprendizado de máquina. Na primeira fase, foi construída uma base integrada entre o *Gaia Catalogue of Nearby Stars* (GCNS) e o *survey* GALAH DR4, permitindo uma caracterização preliminar crono-químio-dinâmica da vizinhança solar, apresentada em *proceedings* científico, além do desenvolvimento de uma ferramenta computacional para visualização de espectros do GALAH DR4. Nesta renovação, pretende-se consolidar essa base, ampliar a análise das populações estelares presentes na amostra e aplicar métodos de redução de dimensionalidade e detecção de anomalias, como t-SNE, UMAP e possíveis algoritmos complementares, para identificar estruturas, tendências e potenciais *outliers* espectrais, químicos ou dinâmicos. Espera-se produzir uma base analisada e documentada, visualizações diagnósticas, comparação metodológica entre abordagens de aprendizado não supervisionado, relatórios e apresentações científicas. Caso candidatos robustos sejam identificados, poderão ser elaborados catálogos ou manuscritos futuros. O projeto também contribuirá para a formação do estudante em programação científica, grandes catálogos astronômicos, estatística aplicada e aprendizado de máquina.

1 Introdução

Texto da Introdução ()

Desde os primeiros avanços da Astronomia moderna (ou seja, com o amplo uso de telescópios) muitas descobertas relevantes ocorreram a partir da análise minuciosa de observações realizadas que identificavam objetos incomuns nos dados coletados. Entretanto, o advento de grandes levantamentos astronômicos e a crescente automatização dos processos observacionais transformaram profundamente essa dinâmica, ao coletar quantidades crescentes e sem precedentes de dados. Missões contemporâneas como, por exemplo, os *surveys* do telescópio espacial *Gaia* com quase 2 bilhões de estrelas observadas, tornando inviável a inspeção manual tradicional das observações coletadas. **Nesse contexto, surge a necessidade do desenvolvimento de métodos automatizados capazes de classificar objetos, identificar padrões, e detectar objetos peculiares de maneira eficiente e robusta**, seja para a limpeza dos dados coletados ou para a detecção de objetos pouco ou não-conhecidos.

A investigação da **vizinhança solar possui papel central** nesse cenário, especialmente **no contexto da arqueologia Galáctica**. Por se tratar da região da Via Láctea para a qual se dispõe das **medidas astrométricas, fotométricas e espectroscópicas mais precisas**, a vizinhança solar funciona como um laboratório natural para o estudo da formação e evolução da Galáxia. A combinação entre paralaxes e movimentos próprios obtidos pelo *Gaia*, além das abundâncias químicas derivadas de espectroscopia de alta resolução de diversos *surveys* espectroscópicos de acompanhamento, tais como o *Gaia*-ESO (Gilmore et al., 2022; Randich et al., 2022), o *The Apache Point Observatory Galactic Evolution Experiment* (APOGEE; Majewski et al., 2017), o *GALactic Archaeology with HERMES survey* (GALAH; Buder et al., 2025), entre outros, permite reconstruir a história dinâmica e química das populações estelares locais. Além disso, a identificação de estrelas quimicamente peculiares, sistemas binários incomuns e estruturas cinemáticas remanescentes de processos de acreção Galáctica contribui diretamente para compreender os mecanismos responsáveis pela evolução do disco Galáctico e pela montagem da Via Láctea ao longo do tempo cósmico. Mais do que isso, a profundidade do estudo que a Galáxia nos permite dado a excelente resolução dos dados propicia um melhor entendimento do comportamento de estrelas em galáxias no geral, ampliando nosso conhecimento desses importantes objetos.

Neste contexto, técnicas de aprendizado de máquina apresentam-se como uma das soluções mais promissoras para a identificação automatizada de objetos e padrões de interesse em grandes bases de dados astronômicos. Esses métodos podem ser treinados para reconhecer eficientemente assinaturas observacionais raras ou discrepantes, ampliando significativamente a capacidade de exploração científica dos levantamentos modernos. Entretanto, é importante destacar que nem toda anomalia detectada possui interesse astrofísico direto.

Como apontam Lochner e Bassett (2021, p.3): “essa ideia de relevância é inerentemente subjetiva: a maioria dos astrônomos não estaria interessada em artefatos em dados que podem ser sinalizados como anômalos, mas alguém responsável pelo controle de qualidade de dados certamente estaria”. Dessa forma, a identificação de artefatos observacionais e inconsistências instrumentais torna-se igualmente importante, uma vez que tais contaminações podem comprometer análises científicas subsequentes. Assim, o desenvolvimento de ferramentas capazes de distinguir anomalias astrofísicas reais de imperfeições observacionais pode contribuir tanto para a descoberta de novos fenômenos quanto para o aprimoramento da qualidade dos dados utilizados em pesquisas astronômicas.

2 Justificativa

Texto da Justificativa

Nas últimas décadas, a Astronomia Observacional tem vivenciado uma revolução tecnológica, com a entrada em operação de grandes telescópios, terrestres e espaciais, que fornecem uma quantidade de dados sem precedentes na História da Ciência, tais como o *Sloan Digital Sky Survey* (SDSS; York et al., 2000), *Two Micron All-Sky Survey* (2MASS; Skrutskie et al., 2006), *Dark Energy Survey* (DES; Abbott et al., 2018) e, notavelmente, o *Legacy Survey of Space and Time* do Observatório Vera C. Rubin (LSST; Ivezić et al., 2019, que fornecerá dados massivos na próxima década), além de muitos outros. Um desses instrumentos é o telescópio espacial *Gaia* (Gaia Collaboration, Prusti et al., 2016), lançado em 2013 e descomissionado em 2025 (com dados finais a serem disponibilizados publicamente ao final de 2026^a). Por meio do levantamento astrométrico mais abrangente já realizado, que proporcionou um catálogo com quase 2 bilhões de estrelas, o *Gaia* tem promovido uma transformação no estudo das populações estelares da Via Láctea. Entretanto, o enorme volume de dados produzido impõe novos desafios metodológicos, especialmente no desenvolvimento de técnicas capazes de processar e interpretar essas informações de maneira automatizada e eficiente.

Tal desafio passa tanto pela otimização do tratamento massivo dos dados, classificando os objetos observado a partir de propriedades previamente conhecidas e bem estabelecidas, quanto pela análise de objetos e eventos que escapam aos padrões esperados. Esse segundo ponto, tradicionalmente, exige uma inspeção humana dedicada, o que acaba sendo incompatível com a escala apresentada por esses grandes levantamentos de dados. Nesse contexto, o desenvolvimento de métodos automatizados voltados para a classificação dos dados, bem como para a detecção e caracterização de *outliers* passa a ser essencial para a exploração científica plena dos dados.

Nesse cenário, técnicas de aprendizado de máquina emergem como ferramentas particularmente promissoras, devido à sua capacidade de analisar grandes volumes de dados de forma eficiente e adaptativa. Esses métodos possibilitam tanto a identificação de inconsistências observacionais quanto a descoberta de anomalias potencialmente associadas a fenômenos astrofísicos raros, incomuns ou ainda desconhecidos (e.g. Ishida et al., 2021; Lochner & Bassett, 2021). Vale ressaltar que tais técnicas podem ser aplicadas a uma miríade de casos, não apenas para a detecção de *outliers* estelares, mas de outras classes de objetos astrofísicos, bem como ser aplicado em outras áreas do conhecimento. Dentro do contexto de um projeto de iniciação científica, especialmente para um aluno em formação na interface entre Astronomia, Fí-

sica, Computação e Ciência de Dados, o domínio desse tipo de ferramenta é de extremo interesse para uma aplicação em uma ampla gama de casos, dentro e fora da astrofísica futuramente, a depender das escolhas do aluno.

Além de seu impacto científico direto, o desenvolvimento e a aplicação dessas técnicas avançadas de análise de dados contribuem para a democratização do acesso à ciência e à formação tecnológica, estando alinhados aos Objetivos de Desenvolvimento Sustentável (ODS) da Organização das Nações Unidas (ONU), em especial os objetivos 4 e 9, relacionados à Educação de Qualidade e à Inovação, respectivamente.

^a<https://www.cosmos.esa.int/web/gaia/data-release-4>

3 Referencial Teórico

Texto do Referencial

O telescópio *Gaia* do *European Space Agency* representa um dos maiores avanços recentes da Astronomia observacional. Desde seu lançamento, a missão vem produzindo medidas astrométricas, fotométricas e espectroscópicas de precisão sem precedentes para quase 2 bilhões de estrelas das distintas componentes da Via Láctea (disco fino e espesso, halo, e até mesmo do bojo), permitindo investigar com elevado detalhamento a estrutura, a dinâmica e a evolução química da Galáxia. Em paralelo, levantamentos espectroscópicos de acompanhamento, tal como o GALAH (Buder et al., 2025), fornecem abundâncias químicas detalhadas e velocidades radiais para milhões de estrelas, bem como catálogos de valor agregado (por exemplo, catálogos com parâmetros orbitais), complementando os dados do *Gaia* e ampliando significativamente o potencial científico da arqueologia Galáctica.

Inserido nesse contexto, o presente trabalho constitui uma continuidade de pesquisas previamente desenvolvidas pelo grupo, nas quais foi realizado o cruzamento entre os catálogos do *Gaia Catalogue of Nearby Stars* (GCNS; com estrelas observadas a até 100 pc do Sol, c.f. Gaia Collaboration, Smart et al., 2021) e do GALAH DR4 com o objetivo de construir uma base integrada contendo informações astrométricas, espectroscópicas e fotométricas das estrelas da vizinhança solar, bem como dos parâmetros químico-dinâmicos derivados de tais observações. A partir dessa base, busca-se agora aprofundar a investigação por meio da aplicação de metodologias de análise não supervisionada, especialmente técnicas de redução de dimensionalidade, como o *t-distributed Stochastic Neighbor Embedding* (t-SNE; van der Maaten & Hinton, 2008) e o Uniform Manifold Approximation and Projection and dimensionality reduc-

tion (UMAP; e.g. Healy & McInnes, 2024). Essas abordagens possibilitam a visualização de estruturas complexas presentes nos dados e favorecem a detecção de populações estelares mais ou menos dominantes e peculiares, subestruturas dinâmicas e possíveis assinaturas de processos evolutivos da Via Láctea, como estratificação e caracterização de diferentes populações estelares (e.g. da Silva & Smiljanic, 2023; Martínez Fernández et al., 2025).

Além da identificação de fenômenos astrofísicos raros ou incomuns, técnicas de aprendizado de máquina também possuem importante aplicação no controle de qualidade dos dados observacionais, permitindo reconhecer artefatos instrumentais, inconsistências espectrais e problemas associados às observações. Dessa forma, tais metodologias contribuem tanto para a descoberta científica quanto para o refinamento dos grandes levantamentos astronômicos modernos (e.g. Ishida et al., 2021; Lochner e Bassett, 2021). Ademais, o desenvolvimento e a aplicação dessas ferramentas computacionais avançadas possuem forte caráter interdisciplinar, promovendo a integração entre Astronomia, Ciência de Dados e Computação. Nesse sentido, o projeto também se alinha aos Objetivos de Desenvolvimento Sustentável (ODS) propostos pela United Nations, especialmente os objetivos 4 e 9, relacionados à Educação de Qualidade e à promoção da Inovação e Infraestrutura Científica e Tecnológica, respectivamente.

4 Objetivos

Texto dos objetivos

Caracterizar as populações estelares comuns ao GCNS e GALAH DR4, identificando as propriedades químico-dinâmicas dessas estrelas, tal como pertencimento a diferentes estruturas da Via Láctea (disco fino e espesso ou halo). Além disso, identificar sistemas raros ou desconhecidos e a partir das identificações criar um catálogo desses objetos para ser compartilhado com a comunidade científica, caso haja um número significativo de anomalias. Ademais, testar e verificar diferentes algoritmos de aprendizagem de máquina para a execução das tarefas descritas a fim de detectar qual ou quais métodos são mais eficientes para isso.

O projeto também tem como objetivo contribuir para a formação de recursos humanos em Astronomia computacional, com treinamento em programação científica, manipulação de grandes catálogos astronômicos, estatística aplicada e técnicas modernas de aprendizado de máquina. As habilidades computacionais desenvolvidas neste projeto podem ser facilmente transferi-

das para outras áreas do conhecimento futuramente, ampliando o potencial interdisciplinar da formação do estudante e alinhando-se aos Objetivos de Desenvolvimento Sustentável (ODS) da Organização das Nações Unidas (ONU), especialmente aqueles relacionados à educação de qualidade e à inovação tecnológica.

5 Metodologia

Descrição da Metodologia

A metodologia deste trabalho, já consolidada na sua primeira fase, é dividida em três etapas principais:

- I. Coleta e processamento de dados: Obtenção e preparação dos dados do *Gaia* e, possivelmente, de outros surveys complementares (Gaia-ESO, GALAH, J-PAS/J-PLUS). O foco será o GCNS (Gaia Collaboration, Smart et al., 2021).

Status: Foi realizado o cruzamento de dados do GCNS com o *survey* espectroscópico de acompanhamento GALAH DR4. Análises preliminares da química-dinâmica dessas estrelas foram realizadas e publicadas em um *proceedings* (c.f. de Andrade et al., 2026). Ademais, o aluno gerou um site (<https://spectraviewer.streamlit.app/>) para visualização de alguns espectros do GALAH DR4 com a finalidade de identificar linhas específicas relacionadas à abundâncias químicas provenientes de diferentes processos (processos r , s , elementos do pico do ferro, entre outros). Agora, o próximo passo é atualizar essa coleta, repetindo os procedimentos já consolidados com dados da nova *Data Release* do *Gaia* o DR4.

- II. Aplicação de técnicas de aprendizado de máquina: Implementação de algoritmos de aprendizado não supervisionado, seguindo abordagens recentes (Ishida et al., 2021; Lochner & Bassett, 2021).

Status: O aluno se encontra em fase de aplicação do t-SNE e UMAP para análise da redução de dimensionalidade dos dados das estrelas. Em uma primeira análise, o estudante já aplicou essa técnica usando dados derivados dos espectros e dos dados nos catálogos de valor agregado do GALAH (i.e. metalicidades, idades, entre outros). Agora estamos ampliando para o uso dos espectros do GALAH, seja por regiões bem definidas (e.g. Traven et al., 2017) ou pelo espectro em sua totalidade. Desafios computacionais estão sendo avaliados e, caso necessário, poderemos enviar uma proposta de uso computacional ao LineA e/ou ao Santos Dumont.

III. Análise e interpretação: Análise crono-químio-dinâmica das populações estelares comuns ao GCNS e GALAH DR4, bem como das anomalias identificadas, determinando sua natureza (medições espúrias, sistemas raros ou outros fenômenos) e suas possíveis implicações astrofísicas.

Status: A análise preliminar da amostra selecionada foi publicada em um *proceedings* do Encontro da Sociedade Brasileira de Astronomia de 2025 (publicamente disponível: de Andrade et al., 2026). Os próximos passos envolvem o detalhamento das populações estelares identificadas, bem como suas abundâncias químicas para além de Fe e Mg (este último considerado um proxy dos elementos α). Ademais, com a melhor caracterização das populações e potenciais anomalias, será possível explorar os efeitos da crono-químio-dinâmica em detalhes.

Os códigos são desenvolvidos em PYTHON para a manipulação e seleção dos dados. Futuramente, a depender de como o projeto se desenvolver, outras linguagens de programação poderão ser usadas, tais como R ou JULIA.

6 Resultados Esperados

Resultados Esperados

Essa proposta trata da segunda fase do projeto, de maneira que alguns resultados já foram alcançados e apresentados em eventos científicos. Até o momento, foi realizada a caracterização químio-dinâmica preliminar da amostra comum ao GCNS e ao GALAH DR4, cujos primeiros resultados foram apresentados em *proceedings* científico, conforme dito acima. Além disso, o aluno desenvolveu uma ferramenta computacional para visualização de espectros do GALAH DR4, voltada à identificação de linhas associadas a diferentes grupos de elementos químicos, incluindo elementos α , elementos do pico do ferro e elementos relacionados aos processos r , s e i . Essa ferramenta poderá ser aprimorada nesta segunda fase e utilizada tanto para a caracterização global da amostra quanto para a inspeção individual de possíveis anomalias e *outliers*. Abaixo seguem alguns dos resultados que esperamos alcançar nesta segunda fase de investigação:

1. Consolidar a base integrada GCNS–GALAH DR4, validando os parâmetros astrométricos, fotométricos, espectroscópicos e químio-dinâmicos utilizados nas análises;
2. Ampliar a caracterização químio-dinâmica da amostra, explorando padrões relacionados às abundâncias químicas (por exemplo: elementos

α , pico do ferro e elementos provenientes dos processos r , s e i , idades estelares e propriedades orbitais;

3. Aplicar e comparar diferentes técnicas de redução de dimensionalidade e detecção de anomalias, tais como t-SNE, UMAP e possíveis algoritmos complementares;
4. Identificar possíveis populações estelares peculiares e potenciais *outliers* espectrais, químicos ou dinâmicos;
5. Desenvolver e aprimorar ferramentas computacionais e visualizações voltadas para a exploração dos dados astronômicos analisados, incluindo a inspeção de espectros e a interpretação das populações estelares e potenciais anomalias;
6. Consolidar a formação do estudante em programação científica, análise de grandes bases de dados astronômicos e aprendizado de máquina aplicado à Astrofísica;
7. Produzir relatórios técnicos, apresentações em eventos científicos e, caso os resultados sejam suficientemente robustos, possíveis produtos científicos adicionais, como catálogos ou manuscritos.

Posto isso, espera-se que os resultados dessa continuação contribuam para a avaliação das populações estelares na vizinhança solar, além da detecção de objetos raros, atípicos ou possivelmente desconhecidos. Caso a detecção dessas anomalias seja bem-sucedida, será possível realizar análises mais aprofundadas dos objetos e criar um ou mais catálogos que poderão ser disponibilizados para a comunidade astronômica.

7 Cronograma esperado e execução de tarefas

Cronograma esperado e execução de tarefas


Por se tratar da renovação de um projeto já em andamento, o cronograma do segundo ano concentra-se na consolidação da base de dados construída na primeira fase, na ampliação dos testes de aprendizado de máquina e na interpretação astrofísica das populações e anomalias em processo de identificação. As atividades estão organizadas de modo a garantir entregas intermediárias e verificáveis, acompanhamento contínuo do estudante e finalização de produtos científicos ao término da vigência da bolsa.

- **Pedro Henrique Rocha de Andrade (aluno):** será responsável pela

execução principal do projeto, incluindo a organização da base GCNS–GALAH DR4, implementação e comparação dos métodos de redução de dimensionalidade e detecção de anomalias, geração das visualizações, inspeção dos candidatos identificados e preparação das versões preliminares dos relatórios e produtos finais.

- **Prof^a. Dr^a. Ana Cecília Soja:** atuará na supervisão científica local do projeto, acompanhando a interpretação astrofísica dos resultados, a definição das estratégias de validação das populações estelares e anomalias identificadas, bem como a revisão dos produtos intermediários e finais.
- **Dr^a. Maria Luiza Linhares Dantas:** atuará na co-orientação científica e metodológica, com ênfase na definição da estratégia crono-químio-dinâmica, seleção de parâmetros astrofísicos relevantes, avaliação dos métodos de aprendizado de máquina aplicados e revisão dos produtos científicos, incluindo possíveis catálogos, apresentações e manuscritos.

O cronograma abaixo resume as principais etapas previstas para o segundo ano da bolsa.



8 Referências

- Abbott, T. M. C., et al. (2018). Dark Energy Survey year 1 results: Cosmological constraints from galaxy clustering and weak lensing. *Physical Review D*, 98(4), 043526. <https://doi.org/10.1103/PhysRevD.98.043526>
- Buder, S., et al. (2025). The GALAH survey: Data release 4., 42, e051. <https://doi.org/10.1017/pasa.2025.26>
- da Silva, A. R., & Smiljanic, R. (2023). Exploring the chemodynamics of metal-poor stellar populations. *A&A*, 677, A74. <https://doi.org/10.1051/0004-6361/202347229>
- de Andrade, P. H. R., Dantas, M., & Soja, A. C. (2026). Stellar properties and chemical features of the Gaia Catalogue of Nearby Stars observed by GALAH DR4. *Boletim da Sociedade Astronômica Brasileira*, 1(37), 308–309. <https://doi.org/10.48550/arXiv.2512.10037>
- Gaia Collaboration, Prusti, T., et al. (2016). The Gaia mission. *A&A*, 595, A1. <https://doi.org/10.1051/0004-6361/201629272>
- Gaia Collaboration, Smart, R. L., et al. (2021). Gaia Early Data Release 3. The Gaia Catalogue of Nearby Stars. *A&A*, 649, A6. <https://doi.org/10.1051/0004-6361/202039498>
- Gilmore, G., et al. (2022). The Gaia-ESO Public Spectroscopic Survey: Motivation, implementation, GIRAFFE data processing, analysis, and final data products. *A&A*, 666, A120. <https://doi.org/10.1051/0004-6361/202243134>
- Healy, J., & McInnes, L. (2024). Uniform manifold approximation and projection. *Nature Reviews Methods Primers*, 4(1), 82. <https://doi.org/10.1038/s43586-024-00363-x>
- Ishida, E. E. O., et al. (2021). Active anomaly detection for time-domain discoveries. *A&A*, 650, A195. <https://doi.org/10.1051/0004-6361/202037709>
- Ivezić, Ž., et al. (2019). LSST: From Science Drivers to Reference Design and Anticipated Data Products. *ApJ*, 873(2), 111. <https://doi.org/10.3847/1538-4357/ab042c>
- Lochner, M., & Bassett, B. A. (2021). ASTRONOMALY: Personalised active anomaly detection in astronomical data. *Astronomy and Computing*, 36, 100481. <https://doi.org/10.1016/j.ascom.2021.100481>
- Majewski, S. R., et al. (2017). The Apache Point Observatory Galactic Evolution Experiment (APOGEE). *AJ*, 154(3), 94. <https://doi.org/10.3847/1538-3881/aa784d>
- Martínez Fernández, J. E., Özdemir, S., Smiljanic, R., Dantas, M. L. L., & da Silva, A. R. (2025). Playing CHESS with stars: I. Search for similar

- stars in large spectroscopic datasets. *A&A*, 704, A61. <https://doi.org/10.1051/0004-6361/202556583>
- Randich, S., et al. (2022). The Gaia-ESO Public Spectroscopic Survey: Implementation, data products, open cluster survey, science, and legacy. *A&A*, 666, A121. <https://doi.org/10.1051/0004-6361/202243141>
- Skrutskie, M. F., et al. (2006). The Two Micron All Sky Survey (2MASS). *AJ*, 131(2), 1163–1183. <https://doi.org/10.1086/498708>
- Traven, G., et al. (2017). The Galah Survey: Classification and Diagnostics with t-SNE Reduction of Spectral Information. *ApJS*, 228(2), 24. <https://doi.org/10.3847/1538-4365/228/2/24>
- van der Maaten, L., & Hinton, G. (2008). Visualizing Data using t-SNE. *Journal of Machine Learning Research*, 9, 2579–2605.
- York, D. G., et al. (2000). The Sloan Digital Sky Survey: Technical Summary. *AJ*, 120(3), 1579–1587. <https://doi.org/10.1086/301513>