



**SERVIÇO PÚBLICO ESTADUAL**

PROCESSO: E-26/\_\_\_\_\_/\_\_\_\_\_/\_\_\_\_\_  
 DATA: \_\_\_\_/\_\_\_\_/\_\_\_\_ FOLHA: \_\_\_\_  
 RUBRICA: \_\_\_\_\_  
 ID FUNCIONAL: \_\_\_\_\_

Declaração assinada pelo/a supervisor/ de vínculo compatível

## Outros Documentos 1

## Outros Documentos 2

## Outros Documentos 3

## Dados Gerais

## Dados Gerais

Título do projeto (divulgável)

# Detecção de Anomalias em Estrelas da Via Láctea: Explorando Dados do {Gaia e Outros Surveys com Aprendizado de Máquina

Resumo em português (divulgável)

Este projeto tem como objetivo detectar anomalias na base de dados do telescópio espacial Gaia, que contém um vasto volume de observações de estrelas da Via Láctea (~2 bilhões de estrelas). Outros importantes surveys, como Gaia-ESO, GALAH e J-PAS/J-PLUS, também poderão ser analisados. Técnicas de aprendizado de máquina serão aplicadas para identificar medições espúrias, sistemas estelares peculiares (e.g., variáveis cataclísmicas), além de potenciais detecções inesperadas. Ele é destinado a um aluno de iniciação científica e busca proporcionar uma introdução ao uso de métodos computacionais avançados em astrofísica, além de treiná-lo na utilização de bases de dados astronômicas.

## Introdução e justificativa

A Via Láctea abriga bilhões de estrelas, cada uma com suas próprias características e trajetórias evolutivas. Grandes surveys, como o Gaia, possibilitam observar a Galáxia com detalhes inéditos, especialmente em relação a paralaxes e movimentos próprios (Gaia Collaboration 2016). No entanto, a enorme quantidade de dados gerados traz o desafio do desenvolvimento de novas técnicas de análise, que permitam que a ciência seja feita de forma automatizada. Os primeiros esforços se concentraram em tratar o volume de dados da forma mais eficiente possível, classificando os objetos observados a partir de suas propriedades conhecidas. Mas e quanto àqueles que não se encaixam nos padrões, ou seja, evento anômolos? Tradicionalmente, observações de objetos fora de padrões exigem intervenção humana para que suas particularidades sejam analisadas. No entanto, esse trabalho manual é inviável para a quantidade de dados geradas pelos surveys contemporâneos. Nesse cenário, o uso de técnicas automatizadas também para a análise de casos especiais é essencial. A ferramenta ideal para esse tipo de trabalho é o aprendizado de máquina, que tem o potencial de analisá-los de forma eficiente, identificando tanto problemas nas observações quanto anomalias que possam indicar fenômenos astrofísicos raros, atípicos ou desconhecidos (e.g. Ishida et al., 2021; Lochner & Bassett, 2021).

## Objetivos

O telescópio espacial *Gaia* já coletou observações de quase 2 bilhões de estrelas na Galáxia e em galáxias satélites próximas. Esse volume massivo sugere a possibilidade de detectar anomalias de diversas naturezas. A identificação de anomalias nos dados do *Gaia*, possivelmente em conjunto com outros *surveys*, tem dois objetivos principais: 1) Identificar detecções espúrias, essenciais para garantir a qualidade das observações; 2) Detectar anomalias estelares, como variáveis cataclísmicas, sistemas estelares atípicos, ou objetos de natureza desconhecida. Ambos os objetivos são valiosos: o primeiro visa limpar amostras para análises em larga escala, enquanto o segundo busca identificar sistemas raros ou desconhecidos. O uso de aprendizado de máquina permite a análise automatizada de grandes volumes de dados, destacando padrões que poderiam ser ignorados em abordagens tradicionais. Este projeto oferece ao aluno a oportunidade de aplicar essas técnicas em pesquisa de ponta, contribuindo para a compreensão da Galáxia.

Plano de trabalho do/a bolsista

O projeto proposto será executado em 12 meses conforme o edital, seguindo o cronograma abaixo detalhado: 1o. Parte (janeiro e fevereiro de 2025) - Coleta dos dados do survey Gaia: familiarização com as ferramentas de buscas, tipos de dados e informações disponíveis. - Processamento dos dados: tratamento dos dados brutos para tabelas de fácil manipulação computacional. 2o. Parte (março a maio de 2025) Dedicção ao estudo de técnicas de aprendizado de máquinas. Ele será dividido entre algoritmos de aprendizado supervisionados e algoritmos não supervisionados. Em relação aos do primeiro tipo, destacamos o Support Vector Machine, Decision Trees e Artificial Neural Networks. 3o. Parte (junho e julho de 2025) Aplicação das técnicas de aprendizado de máquinas aos dados previamente coletados, testando os diferentes algoritmos estudados. 4o. Parte (agosto a outubro de 2025) Análise dos resultados encontrados e eventual aplicação da metodologia desenvolvida a outros surveys, para além do Gaia. 5o. Parte (novembro e dezembro de 2025) Compilação dos resultados na forma de artigo científico, a ser apresentado em eventos da área e publicado em revistas especializadas.

## Material e métodos

**SERVIÇO PÚBLICO ESTADUAL**

PROCESSO: E-26/\_\_\_\_\_/\_\_\_\_\_/\_\_\_\_\_  
 DATA: \_\_\_\_/\_\_\_\_/\_\_\_\_ FOLHA: \_\_\_\_  
 RUBRICA: \_\_\_\_\_  
 ID FUNCIONAL: \_\_\_\_\_

A metodologia deste trabalho é dividida em três etapas principais: I. Coleta e processamento de dados:} Obtenção e preparação dos dados do Gaia e, possivelmente, de outros complementares (Gaia-ESO, GALAH, J-PAS/J-PLUS). O foco será o Gaia Catalogue of Nearby Stars (GCNS) (Gaia Collaboration et al., 2021). II. Aplicação de técnicas de aprendizado de máquina:} Implementação de algoritmos de aprendizado não supervisionado, seguindo abordagens recentes (Ishida et al., 2021; Lochner & Bassett, 2021). III. Análise e interpretação:} Análise das anomalias identificadas, determinando sua natureza (medições espúrias, sistemas raros ou outros fenômenos) e suas possíveis implicações astrofísicas. Os códigos serão desenvolvidos em python e/ou R, além de sql, para a manipulação e seleção dos dados.

### Forma de análise dos resultados

Durante a busca por anomalias no GCNS, esperamos encontrar tanto medições espúrias quanto conjuntos atípicos ou raros de estrelas, como variáveis cataclísmicas (por exemplo, Gansicke et al., 2009; Knigge et al., 2011), cujos espectros apresentam características distintas. Se a análise do GCNS for bem-sucedida, ela poderá ser expandida para os dados completos do Gaia, envolvendo a análise de quase 2 bilhões de estrelas. Para isso, poderão ser usadas as plataformas online da Agência Espacial Europeia (ESA). Também é importante mencionar que este projeto introduzirá o aluno ao uso prático de aprendizado de máquina aplicado à astrofísica, preparando-o para futuros estudos e pesquisas, tanto na astronomia quanto em outras áreas. O aluno desenvolverá novas habilidades em programação, análise de dados e consulta a grandes bases de dados.

## Potenciais veículos de apresentação de resultados

Os resultados obtidos contribuirão para a avaliação da qualidade das observações do /emph{Gaia} (e de outros surveys, se analisados), além da detecção de objetos raros, atípicos ou possivelmente desconhecidos. Após a detecção dessas anomalias, será possível realizar análises mais aprofundadas dos objetos e criar um ou mais catálogos que poderão ser disponibilizados para a comunidade astronômica. Caso o projeto seja bem-sucedido, espera-se também a produção de um artigo científico a ser submetido para publicação em uma revista internacional de impacto com avaliação por pares, como *Astronomy and Computing*, *Astronomy & Astrophysics*, ou *Monthly Notices of the Royal Astronomical Society*.

## Local de execução da pesquisa

Instituto Federal Fluminense, Campus Bom Jesus do Itabapoana e Pontifícia Universidad Católica de Chile. Destaca-se que ambas instituições possuem os equipamentos necessários para a realização da pesquisa.

### Bibliografia relacionada ao projeto

Gaia Collaboration et al. (2016). The Gaia mission. *A&A*, 595, Article A1, A1. <https://doi.org/10.1051/0004-6361/201629272> Gaia Collaboration et al. (2021). Gaia Early Data Release 3. The Gaia Catalogue of Nearby Stars. *A&A*, 649, Article A6, A6. <https://doi.org/10.1051/0004-6361/202039498> Gansicke, B. T., et al. (2009). SDSS unveils a population of intrinsically faint cataclysmic variables at the minimum orbital period. *MNRAS*, 397 (4), 2170–2188. <https://doi.org/10.1111/j.1365-2966.2009.15126.x> Ishida, E. E. O., et al. (2021). Active anomaly detection for time-domain discoveries. *A&A*, 650, Article A195, A195. <https://doi.org/10.1051/0004-6361/202037709> Knigge, C., Baraffe, I., & Patterson, J. (2011). The Evolution of Cataclysmic Variables as Revealed by Their Donor Stars. *ApJS*, 194 (2), Article 28, 28. <https://doi.org/10.1088/0067-0049/194/2/28> Lochner, M., & Bassett, B. A. (2021). ASTRONOMALY: Personalised active anomaly detection in astronomical data. *Astronomy and Computing*, 36, Article 100481, 100481. <https://doi.org/10.1016/j.ascom.2021.100481>

## Especialidade 1

## Astronomia Estelar

## Especialidade 2

## Especialidade 3

## Especialidade 4

|                |
|----------------|
| Palavra Chave1 |
|----------------|

## Gaia

## Palavra Chave2

## Anomalias

## Palavra Chave3

## Palavra Chave4

