

Detecção de Anomalias em Estrelas da Via Láctea: Explorando Dados do *Gaia* e Outros Surveys com Aprendizado de Máquina

Ana Cecília Soja^{*}, Maria Luiza Linhares Dantas[†], Pedro Henrique Rocha de Andrade¹

October 17, 2024

Resumo

Este projeto tem como objetivo detectar anomalias na base de dados do telescópio *Gaia*, que contém um vasto volume de observações de estrelas da Via Láctea ($\lesssim 2$ bilhões de estrelas). Outros *surveys*, como *Gaia*-ESO, GALAH e J-PAS/J-PLUS, também poderão ser analisados. Técnicas de aprendizado de máquina serão aplicadas para identificar medições espúrias, sistemas estelares peculiares (e.g., variáveis cataclísmicas), além de potenciais detecções inesperadas. O projeto é destinado a um aluno de iniciação científica e busca proporcionar uma introdução ao uso de métodos computacionais avançados em astrofísica, além de treiná-lo na utilização de bases de dados astronômicas.

1 Introdução

A Via Láctea abriga bilhões de estrelas, cada uma com suas próprias características e trajetórias evolutivas. Grandes *surveys*, como o *Gaia*, possibilitam observar a Galáxia com detalhes inéditos, especialmente em relação a paralaxes e movimentos próprios (Gaia Collaboration et al., 2016). No entanto, a enorme quantidade de dados gerados traz o desafio do desenvolvimento de novas técnicas de análise, que permitam que a ciência seja feita de forma automatizada.

Os primeiros esforços se concentraram em tratar o volume de dados da forma mais eficiente possível, classificando os objetos observados a partir de suas propriedades conhecidas. Mas e quanto àqueles que não se encaixam nos padrões, ou seja, evento anômalo? Tradicionalmente, observações de objetos fora de padrões exigem intervenção humana para que suas particularidades sejam analisadas. No entanto, esse trabalho manual é inviável para a quantidade de dados gerados pelos *surveys* contemporâneos. Nesse cenário, o uso de técnicas automatizadas também para a análise de casos especiais é essencial.

A ferramenta ideal para esse tipo de trabalho é o aprendizado de máquina, que tem o potencial de analisá-los de forma eficiente, identificando tanto problemas nas observações quanto anomalias que possam indicar fenômenos astrofísicos raros, atípicos ou desconhecidos (e.g. Ishida et al., 2021; Lochner & Bassett, 2021).

2 Justificativa

O telescópio espacial *Gaia*, lançado há quase uma década, já coletou observações de quase 2 bilhões de estrelas na Galáxia e em galáxias satélites próximas. Esse volume massivo sugere a possibilidade de detectar anomalias de diversas naturezas. A identificação de anomalias nos dados do *Gaia*, possivelmente em conjunto com outros *surveys*, tem dois objetivos principais:

1. Identificar detecções espúrias, essenciais para garantir a qualidade das observações;

^{*}Instituto Federal Fluminense, campus Bom Jesus do Itabapoana

[†]Pontificia Universidad Católica de Chile

2. Detectar anomalias estelares, como variáveis cataclísmicas, sistemas estelares atípicos, ou objetos de natureza desconhecida.

Ambos os objetivos são valiosos: o primeiro visa limpar amostras para análises em larga escala, enquanto o segundo busca identificar sistemas raros ou desconhecidos. O uso de aprendizado de máquina permite a análise automatizada de grandes volumes de dados, destacando padrões que poderiam ser ignorados em abordagens tradicionais. Este projeto oferece ao aluno a oportunidade de aplicar essas técnicas em pesquisa de ponta, contribuindo para a compreensão da Galáxia, ao mesmo tempo que aprende habilidades que são úteis em áreas diversas do Conhecimento.

3 Metodologia

A metodologia deste trabalho é dividida em três etapas principais:

1. **Coleta e processamento de dados:** Obtenção e preparação dos dados do *Gaia* e, possivelmente, de outros *surveys* complementares (*Gaia*-ESO, GALAH, J-PAS/J-PLUS). O foco será o *Gaia* Catalogue of Nearby Stars (GCNS) (Gaia Collaboration et al., 2021).
2. **Aplicação de técnicas de aprendizado de máquina:** Implementação de algoritmos de aprendizado não supervisionado, seguindo abordagens recentes (Ishida et al., 2021; Lochner & Bassett, 2021).
3. **Análise e interpretação:** Análise das anomalias identificadas, determinando sua natureza (medições espúrias, sistemas raros ou outros fenômenos) e suas possíveis implicações astrofísicas.

Os códigos serão desenvolvidos em PYTHON e/ou R, além de SQL, para a manipulação e seleção dos dados.

4 Resultados Esperados

Durante a busca por anomalias no GCNS, esperamos encontrar tanto medições espúrias quanto conjuntos atípicos ou raros de estrelas, como variáveis cataclísmicas (por exemplo, Gänsicke et al., 2009; Knigge et al., 2011), cujos espectros apresentam características distintas.

Se a análise do GCNS for bem-sucedida, ela poderá ser expandida para os dados completos do *Gaia*, envolvendo a análise de quase 2 bilhões de estrelas. Para isso, poderão ser usadas as plataformas online da Agência Espacial Europeia (ESA).

Os resultados obtidos contribuirão para a avaliação da qualidade das observações do *Gaia* (e de outros *surveys*, se analisados), além da detecção de objetos raros, atípicos ou possivelmente desconhecidos. Após a detecção dessas anomalias, será possível realizar análises mais aprofundadas dos objetos e criar um ou mais catálogos que poderão ser disponibilizados para a comunidade astronômica. Caso o projeto seja bem-sucedido, espera-se também a produção de um artigo científico a ser submetido para publicação em uma revista internacional de impacto com avaliação por pares, como *Astronomy and Computing*, *Astronomy & Astrophysics*, ou *Monthly Notices of the Royal Astronomical Society*.

Também é importante mencionar que este projeto introduzirá o estudante ao uso prático de aprendizado de máquina aplicado à astrofísica, preparando-o para futuros estudos e pesquisas, tanto na astronomia quanto em outras áreas. O aluno desenvolverá novas habilidades em programação, análise de dados e consulta a grandes bases de dados.

Referências

- Gaia Collaboration et al. (2016). The Gaia mission. *A&A*, 595, Article A1, A1. <https://doi.org/10.1051/0004-6361/201629272>
- Gaia Collaboration et al. (2021). Gaia Early Data Release 3. The Gaia Catalogue of Nearby Stars. *A&A*, 649, Article A6, A6. <https://doi.org/10.1051/0004-6361/202039498>
- Gänsicke, B. T., et al. (2009). SDSS unveils a population of intrinsically faint cataclysmic variables at the minimum orbital period. *MNRAS*, 397(4), 2170–2188. <https://doi.org/10.1111/j.1365-2966.2009.15126.x>
- Ishida, E. E. O., et al. (2021). Active anomaly detection for time-domain discoveries. *A&A*, 650, Article A195, A195. <https://doi.org/10.1051/0004-6361/202037709>
- Knigge, C., Baraffe, I., & Patterson, J. (2011). The Evolution of Cataclysmic Variables as Revealed by Their Donor Stars. *ApJS*, 194(2), Article 28, 28. <https://doi.org/10.1088/0067-0049/194/2/28>
- Lochner, M., & Bassett, B. A. (2021). ASTRONOMALY: Personalised active anomaly detection in astronomical data. *Astronomy and Computing*, 36, Article 100481, 100481. <https://doi.org/10.1016/j.ascom.2021.100481>